

Küresel Özgürlük Endeksi: İstatistiksel Bir Perspektif

Ve

Veri Analitiği

Hazırlayan: Emirhan Kunt

NO: 173323054

Marmara Üniversitesi İstatistik Bölümü İstatistiksel Yazılımlar 2(IST3014)

Veriye Kısa Bir Bakış:

Bu çalışmada kullanılan veri seti, 1941 yılından bu yana dünya genelindeki siyasi haklar ve sivil özgürlükleri gözlemleyen bağımsız kuruluş **Freedom House** tarafından derlenmiştir. Analizimiz, küresel demokrasinin bir "snapshot" (anlık görüntüsü) niteliğinde olan **2016 yılı** verilerine odaklanmaktadır. Bu veriler üzerinden kurulan modeller, bir ülkenin sadece ismine veya bölgesine bakarak değil, yapısal parametrelerine bakarak özgürlük düzeyini tahmin etmeyi amaçlamaktadır.

Dünya tarihi boyunca "özgürlük" kavramı, toplumların nefes almasını belirleyen en temel hayati belirti olmuştur. Ancak bu kavramı sadece felsefi bir ideal olarak değil, bir toplumun hücrelerine kadar işleyen sosyopolitik bir gerçeklik olarak ele almak gerekir. Freedom House tarafından derlenen küresel veriler, aslında kâğıt üzerindeki rakamlardan çok daha fazlasını; milyonlarca insanın yaşam biçimini, adalete olan erişimini ve sesini duyurabilme kapasitesini temsil etmektedir. Bu çalışmanın odağında yer alan 2016 yılı, insanlık tarihinin son dönemecindeki en kritik "duraklardan" biridir.

Bir Çağın Sonu ve Yeni Bir Gerçeklik: 2016

2016 yılına gelindiğinde dünya, yirminci yüzyılın sonundaki o büyük demokratik iyimserliğin yavaş yavaş yerini sert bir gerçekçiliğe bıraktığı bir atmosferin içindeydi. Bu yıl, küresel düzenin sadece coğrafi sınırlarla değil, aynı zamanda değerler sistemindeki kırılmalarla yeniden şekillendiği bir dönemi temsil eder. 2000'li yılların başındaki teknolojik devrim ve küreselleşme dalgasının getirdiği "herkes için özgürlük" vaadi, 2016 itibarıyla yerini güvenlik kaygılarına, yükselen duvarlara ve otoriter eğilimlerin yeniden canlanmasına bırakmıştır. Bu veriler, aslında bir illüzyonun bitişini ve dünyanın kendi gerçeğiyle yüzleşmesini belgelemektedir.

Arap Baharının İki Farklı Yüzü

Dünyanın en sancılı bölgelerinden biri olan Orta Doğu ve Kuzey Afrika hattında, 2011 yılında başlayan büyük uyanışın izleri 2016 yılında artık iyice kristalleşmiş durumdaydı. Bu süreçte yaşananlar, verinin içinde iki zıt kutup olarak kendine yer bulur.

Tunus, bu büyük dalganın başladığı yer olarak, 2016 yılına gelindiğinde bölgenin en umut verici istisnası haline dönüşmüştü. Yasemin Devrimi'nin ardından kurumsal bir dönüşüm sürecine giren ülke, çevresindeki yangın yerine dönmüş komşularına rağmen sivil iradeyi ve toplumsal uzlaşmayı ayakta tutmayı başarmıştır. Tunus örneği, bir toplumun kendi kaderini tayin etme iradesinin, bölgesel kaderin üzerine çıkabileceğini gösteren nadir bir başarı hikayesidir. Bu, sadece bir ülkenin değil, bir bölgenin de "özgürleşebileceğine" dair yaşayan tek kanıt niteliğindedir.

Buna karşılık **Suriye**, aynı dönemin en karanlık trajedisi olarak karşımıza çıkar. 2016 yılı, Suriye iç savaşının en şiddetli dönemlerinden birine şahitlik ederken, bu durum ülkenin toplumsal ve siyasi dokusunun tamamen parçalanmasıyla sonuçlanmıştır. Sivil hayatın tamamen yerle bir olduğu, temel hakların çatışma gölgesinde yok sayıldığı Suriye, küresel özgürlük endeksindeki en derin uçurumu temsil etmektedir. Suriye'deki bu durum, bir devletin işlevsizleştiği ve toplumun korumasız kaldığı bir ortamda özgürlüğün nasıl bir lüks haline gelebileceğinin en trajik ispatıdır.

Baharın kışa döndüğü başka bir yer de Mısır'dır. 2011'de Tahrir Meydanı ile özgürlük umudunun merkezi olan Mısır, 2016 verilerinde tam bir hayal kırıklığı olarak karşımıza çıkar. 2013'teki askeri müdahale sonrası Sisi yönetiminin askeri müdahale ve ardından gelen sert yönetim anlayışı, Mısır'ı özgürleşme yolundan hızla uzaklaştırarak baskıcı bir yapıya geri döndürmüştür. Mısır örneği, özgürlüğün bir kez kazanıldığında sonsuza dek baki kalmadığını, kurumlar zayıf olduğunda bir gecede nasıl kaybedilebileceğinin en net belgesidir. Mısır "Kısmen Özgür" kategorisinden hızla "Özgür Değil" (7) kategorisine düşmüştür.

Küresel Bir Kriz: Batı'daki Çatlaklar ve Popülizm

2016'nın hikayesi sadece Orta Doğu ile sınırlı değildir. Bu yıl aynı zamanda yerleşik Batı demokrasilerinin de sarsıldığı bir döneme işaret eder. Avrupa ve Amerika kıtasında yükselen popülist hareketler, göçmen krizi ve ekonomik eşitsizlikler, demokratik kurumların üzerine ağır bir yük bindirmiştir. Verilerdeki bu küresel eğilim, özgürlüğün sadece "gelişmekte olan" ülkelerin bir mücadelesi olmadığını; en köklü sistemlerin bile zaman zaman kendi içindeki fırtınalarla, kutuplaşmalarla ve kurumsal aşınmalarla sınındığını göstermektedir.

Sonuç Olarak

Elimizdeki bu veri havuzu, 2016 yılının dünyasını bize anlatırken aslında bir uyarıda bulunmaktadır. Özgürlük, bir kez kazanıldığında sonsuza dek baki kalan bir durum değil; her gün yeniden kazanılması gereken hassas bir dengedir. Tunus'taki umut ışığından Suriye'deki yıkıma, Avrupa'daki kurumsal aşınmalardan Asya'daki otoriterleşmeye kadar tüm bu tablo, insanlığın ortak mücadelesinin bir dökümüdür. Bu analiz, sadece istatistiksel bir çalışma değil, dünyanın o 2016'daki ruh halini anlama ve geleceğe dair bir perspektif geliştirme çabasıdır.

VERİNİN HAZIRLANIŞI VE İŞLENİŞİ:

Öncelikle analizimizde kullandığımız kütüphanelerden bahsetmek isterim.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sb
from sklearn.model_selection import train_test_split, KFold, cross_val_score, GridSearchCV
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_percentage_error
from sklearn.linear_model import LinearRegression, Lasso, LassoCV, Ridge, RidgeCV, ElasticNet, ElasticNetCV
from sklearn.decomposition import PCA
from sklearn.cross_decomposition import PLSRegression
from sklearn.neighbors import KNeighborsRegressor
from sklearn.svm import SVR
from sklearn.tree import DecisionTreeRegressor, plot_tree
from sklearn.ensemble import RandomForestRegressor, BaggingRegressor, GradientBoostingRegressor
from sklearn.neural_network import MLPRegressor
```

Bu analizimizde veri manipülasyonu için Pandas, bilimsel hesaplamalar için NumPy, temel görselleştirme ve veri ile ilgili bulguları grafiğe dökmek için Matplotlib, görselleştirme (ısı haritası, kutu grafiği vb.) için daha profesyonel ve istatistik odaklı olan Seaborn ve makine öğrenmesi kısmında Scikit-learn kütüphaneleri kullanıldı.

Veriyi hazırlarken kullandığımız adımlar ise şöyledir;

```
# =====
# 1. VERİ HAZIRLIĞI
# =====
data = pd.read_csv(r"C:\Users\Emirhan Kunt\Desktop\Programlama\Python Klasörü\data\freedom.csv")
data_2016 = data[data["year"] == 2016].copy()

data_final = pd.get_dummies(data_2016, columns=['Status', 'Region_Name'], drop_first=True)
y = data_final["CL"]
X = data_final.drop(["CL", "country", "year"], axis=1).fillna(data_final.mean(numeric_only=True))

x_egitim, x_test, y_egitim, y_test = train_test_split(X, y, test_size=0.25, random_state=34)

scl = StandardScaler()
x_egitim_scl = scl.fit_transform(x_egitim)
x_test_scl = scl.transform(x_test)
```

Analizimizin ilk adımı, yerel dizinde bulunan freedom.csv dosyasının **Pandas** kütüphanesi kullanılarak sisteme yüklenmesidir. Ham veri seti, 1941 yılından günümüze kadar olan tüm yılları kapsadığı için, odak noktamız olan **2016** yılı verileri `data[data["year"] == 2016]` komutuyla filtrelenmiştir. Bu filtreleme, modellerimizin zamanın gürültüsünden arınmasını ve sadece o yıla ait küresel özgürlük profilini öğrenmesini sağlar. Bilgisayarlar "Avrupa",

"Asya" veya "Özgür" gibi metinsel ifadeler üzerinde matematiksel işlem yapamazlar. Bu sorunu aşmak için `pd.get_dummies` fonksiyonunu kullandık. Bu işlemle, Status (Özgürlük Durumu) ve Region_Name (Bölge İsmi) gibi metin bazlı sütunlar, 0 ve 1'lerden oluşan sayısal sütunlara dönüştürülmüştür. `drop_first=True` parametresi ise "Dummy Variable Trap" (Kukla Değişken Tuzağı) denilen, değişkenler arasında tam bağımlılık oluşması riskini bertaraf etmek için eklenmiştir. Tahmin etmek istediğimiz "Sivil Özgürlükler (CL)" puanı bağımlı değişken (y) olarak atanmıştır. Ülke isimleri ve yıl bilgisi gibi tahmin gücü olmayan veya modelin taraflı öğrenmesine sebep olabilecek sütunlar ise `X.drop` komutuyla veri setinden çıkarılmıştır. Kalan sütunlar, modelin "eğitim materyali" olan öznitelikler (features) setini oluşturmuştur. Farklı değişkenlerin farklı ölçeklerde (bazıları 1-7 arası, bazıları 0-1 arası) olması, modellerin (özellikle KNN ve SVR) büyük sayılara sahip değişkenlere daha fazla önem vermesine yol açabilir. Bu adaletsizliği önlemek adına `StandardScaler` kullanılarak tüm veriler, ortalaması 0 ve varyansı 1 olacak şekilde standartlaştırılmıştır. Bu adım, modellerin her değişkene eşit mesafede yaklaşmasını sağlar. Modelin sadece mevcut veriyi ezberlemesini değil, hiç görmediği ülkeler hakkında da mantıklı tahminler yapabilmesini sağlamak amacıyla veri seti **%75 eğitim** ve **%25 test** olmak üzere ikiye bölünmüştür. `random_state=34` parametresi, bu bölme işleminin her seferinde aynı şekilde yapılmasını ve sonuçlarımızın tekrarlanabilir (reproducible) olmasını garanti altına alır. Analiz sürecinde 13 farklı algoritma yarıştırdığı için, her bir modelin performansını manuel olarak takip etmek yerine sistematik bir veri depolama yapısı kurgulanmıştır. Kodun bu bölümünde yer alan `model_isimleri`, `r2_skorlari` ve `mape_skorlari` isimli boş listeler, her bir modelden elde edilen istatistiksel çıktıları raporlamak üzere tanımlanmış dijital arşivlerdir.


Bu yapıya işlevsellik kazandırmak amacıyla oluşturulan `skor_kaydet` fonksiyonu ise projenin otomasyon merkezidir. Bu fonksiyon, her modelin tahminlerini gerçek değerlerle kıyaslayarak R^2 (belirlenme katsayısı) ve MAPE (yüzdesel hata) değerlerini saniyeler içinde hesaplamaktadır. MAPE değerinin 100 ile çarpılarak listeye eklenmesi, raporlama aşamasında hataların doğrudan "yüzde" cinsinden okunabilmesini sağlamak amacıyla yapılmış bir ölçeklendirme işlemidir. Bu sistem sayesinde, projenin sonunda tüm modellerin performansını tek bir tabloda toplamak ve bilimsel bir kıyaslama yapmak mümkün hale gelmiştir.

DOĞRUSAL VE BOYUT İNDİRGEME MODELLERİ:

OLSR Modeli:

```
# =====  
# 2. DOĞRUSAL VE BOYUT İNDİRGEME MODELLERİ  
# =====  
  
# --- 1. OLS (Linear Regression) ---  
ols_model = LinearRegression().fit(x_egitim_scl, y_egitim)  
ols_pred = ols_model.predict(x_test_scl)  
skor_kaydet("OLS", y_test, ols_pred)  
# [GÖRSEL 1]  
mt.figure()  
mt.scatter(y_test, ols_pred, alpha=0.6, color='blue')  
mt.plot([y.min(), y.max()], [y.min(), y.max()], 'r--', lw=2)  
mt.title("OLS: Gerçek vs Tahmin (Regresyon Çizgisi)")  
mt.show()
```

OLSR modeli, bağımlı değişkenimiz olan "Sivil Özgürlükler" ile bağımsız değişkenlerimiz arasındaki doğrusal ilişkiyi, gerçek değerler ile tahmin edilen değerler arasındaki hata kareler toplamını minimize ederek kurmaya çalışır. OLS modelinin bu çalışmadaki temel görevi, daha ileri seviye düzenlenileştirilmiş (Lasso, Ridge) veya boyut indirgenmiş (PLS) modeller için bir kıyaslama eşiği (baseline) oluşturmaktır.



Kod içerisinde uygulanan saçılım grafiği (Scatter Plot), OLS modelinin başarısını görselleştirmek adına kritik bir öneme sahiptir. Grafikteki **kırmızı kesikli çizgi**, hatasız bir tahmini temsil eden "Mükemmel Tahmin Hattı"dır. Veri noktalarının bu çizgi etrafındaki dağılımı, modelin dünyadaki özgürlük puanlarını tahmin etme kabiliyetini doğrudan sergiler.

2016 yılı verileri üzerinde yapılan bu ilk denemede, noktaların çizgiye yakınlığı modelin genel eğilimi yakaladığını gösterse de, çizgiden uzaklaşan noktalar basit doğrusal modellerin "aykırı ülkeleri" ve karmaşık sosyopolitik yapıları açıklamakta zorlandığını, dolayısıyla daha gelişmiş algoritmalara ihtiyaç duyulduğunu istatistiksel olarak kanıtlamaktadır.

PCR Modeli:

```
# --- 2. PCR (Principal Component Regression) ---
from sklearn.model_selection import cross_val_score, KFold

# 1. En iyi bileşen sayısını bulmak için MSE hesaplama döngüsü
mse_listesi = []
cv = KFold(n_splits=10, shuffle=True, random_state=34)

for i in range(1, X.shape[1] + 1):
    pca = PCA(n_components=i)
    X_reduced = pca.fit_transform(x_egitim_scl)
    score = -1 * cross_val_score(LinearRegression(), X_reduced, y_egitim, cv=cv, scoring='neg_mean_squared_error').mean()
    mse_listesi.append(score)


# 2. Grafikteki en düşük noktayı (6. bileşen) baz alarak nihai modeli kurma
pca_final = PCA(n_components=6) # Grafikteki çakılma noktası 6 olarak belirlendi
X_pcr_egitim = pca_final.fit_transform(x_egitim_scl)
pcr_model = LinearRegression().fit(X_pcr_egitim, y_egitim)

# 3. Test seti tahmini ve skor kaydı
X_pcr_test = pca_final.transform(x_test_scl)
pcr_pred = pcr_model.predict(X_pcr_test)
skor_kaydet("PCR (n=6)", y_test, pcr_pred)

mt.figure()
mt.plot(np.arange(1, X.shape[1] + 1), mse_pcr, '-v-', color='orange')
mt.title("PCR: Bileşen Sayısına Göre Hata (MSE)")
mt.show()
```

Analizimizin bu aşamasında uyguladığımız PCR modeli, klasik regresyon yöntemlerinden farklı bir felsefeyle çalışmaktadır. PCR modelinin kurulumunda en kritik adım, modelin karmaşıklığını ve hata oranını belirleyen bileşen sayısının seçimidir. Bu çalışmada, bileşen sayısı subjektif bir kararla değil, **10-katlı Çapraz Doğrulama (10-Fold Cross-Validation)** yöntemiyle belirlenmiştir. Hazırlanan 'Bileşen Sayısına Göre MSE' grafiğinde, hata oranının 5. bileşenden 6. bileşene geçişte radikal bir düşüş gösterdiği ve bu noktadan sonra minimize

olduğu gözlemlenmiştir.



Bu veriden hareketle, modeldeki bileşen sayısı **n=6** olarak optimize edilmiştir. Bu yaklaşım, modelin verideki gizli yapıları yakalamasını sağlarken, gereksiz değişken gürültüsünden (overfitting) kaçınmasına olanak tanımıştır. Sonuç olarak PCR modelimiz, basit bir regresyonun ötesine geçerek verinin boyutunu en verimli şekilde indirgeyen bir yapıya kavuşturulmuştur.


PLSR Modeli:

Analiz sürecinde kullanılan en güçlü boyut indirgeme yöntemi olan PLS, sadece bağımsız değişkenlerin (X) kendi içindeki değişimine değil, bu değişkenlerin hedef değişken (Y) ile olan etkileşimine odaklanır. Kod bloğunda `PLSRegression(n_components=2)` komutuyla, tüm veri seti en önemli iki "gizli değişkene" (latent variables) indirgenmiştir.

```
# --- 3. PLS (Partial Least Squares) ---
pls_model = PLSRegression(n_components=2).fit(x_egitim_scl, y_egitim)
pls_pred = pls_model.predict(x_test_scl).flatten()
skor_kaydet("PLS", y_test, pls_pred)
# [GÖRSEL 3] Bileşenlerin Hedefe Göre Dağılımı
X_pls = pls_model.transform(x_egitim_scl)
mt.figure()
mt.scatter(X_pls[:, 0], X_pls[:, 1], c=y_egitim, cmap='plasma')
mt.title("PLS: Bileşen 1 vs Bileşen 2 (Renkler CL Puanı)")
mt.show()
```

Kodun devamında yer alan `pls_model.transform` işlemi, yüksek boyutlu karmaşık veriyi bu iki temel bileşene iz düşürerek görselleştirmeye hazır hale getirir. `mt.scatter` fonksiyonu ile

oluşturulan grafikte, ülkeler bu iki yeni bileşen eksenine yerleştirilirken; her bir noktanın rengi ($c=y_egitim$), o ülkenin gerçek **Sivil Özgürlük (CL)** puanını temsil edecek şekilde ($cmap='plasma'$) ayarlanmıştır. Bu yaklaşım, modelin veriyi sadece tahmin etmekle kalmayıp, ülkeler arasındaki demokratik farkları ne kadar keskin bir şekilde ayrıştırabildiğini gözler önüne sermektedir.



, Grafik, PLS modelinin başarısını kanıtlayan bir "kümeleme" haritası niteliğindedir.

Grafikten elde edilen temel çıkarımlar şunlardır:

- **Renk Gruplandırması ve Ayrışma:** Grafikte düşük CL puanına sahip ülkeler (açık/sarı tonlar) ile yüksek puanlı ülkelerin (koyu/mor tonlar) birbirinden net bir hatla ayrıldığı görülmektedir. Bu, PLS'in oluşturduğu 1. ve 2. bileşenlerin, dünyadaki özgürlük seviyelerini açıklayan "ana karakteri" başarıyla yakaladığını gösterir.
- **Bileşenlerin Anlamı:** Yatay eksendeki 1. Bileşen, verideki varyansın en büyük kısmını ve CL puanı ile olan en güçlü bağı temsil eder. Noktaların soldan sağa doğru renk değiştirerek dizilmesi, 1. Bileşenin aslında bir "Özgürlük Endeksi" gibi çalıştığını kanıtlar.
- **Kümelenme Dinamiği:** Benzer özgürlük puanına sahip ülkelerin grafikte birbirine yakın konumlarda kümelenmesi, modelin sadece matematiksel bir hata minimizasyonu yapmadığını, aynı zamanda sosyopolitik benzerlikleri de doğru bir şekilde boyut indirgeme sürecine dahil ettiğini doğrulamaktadır.


Ridge Modeli:

Ridge regresyonu, OLS modelinin en büyük zayıflığı olan "aşırı öğrenme" (overfitting) ve "çoklu doğrusal bağlantı" problemlerine karşı geliştirilmiş bir L2 düzenleme

(regularization) yöntemidir. Kod bloğunda görüldüğü üzere, modelin başarısını belirleyen en kritik parametre olan alpha (lambda) değerini rastgele seçmek yerine, geniş bir yelpazede ($10^{**np.linspace(10, -2, 100)*0.5}$) test edilmiştir.

```
# --- 4. Ridge ---
ridge_cv = RidgeCV(alphas=np.logspace(-6, 6, 13)).fit(x_egitim_scl, y_egitim)
ridge_model = Ridge(alpha=ridge_cv.alpha_).fit(x_egitim_scl, y_egitim)
skor_kaydet("Ridge", y_test, ridge_model.predict(x_test_scl))
# [GÖRSEL 4] Katsayı Önem Barı
mt.figure()
pd.Series(ridge_model.coef_, index=X.columns).sort_values().plot(kind='barh', color='cyan')
mt.title("Ridge: Değişken Katsayılarının Sönümlenmesi")
mt.show()
```

RidgeCV fonksiyonu kullanılarak yapılan bu işlem, modelin farklı alpha değerleri altında çapraz doğrulama (Cross-Validation) yaparak en düşük hata oranını veren "altın değeri" bulmasını sağlar. Bu sayede, modelimiz hem verideki önemli bilgileri korumuş hem de katsayıların anlamsızca büyümesine engel olarak daha kararlı (robust) bir tahmin mekanizması oluşturmuştur.



Grafik, Ridge regresyonunun "ceza" mekanizmasının değişkenler üzerinde nasıl çalıştığını gösteren bir katsayı yol haritasıdır. Grafiği şu şekilde okumak gerekir:

- **Katsayıların Daralması (Shrinkage):** Grafikte sağdan sola (veya alpha değeri büyümeye bağlı olarak) gidildiğinde, farklı renklerle temsil edilen değişken katsayılarının sıfıra doğru yaklaştığı görülmektedir. Bu, Ridge regresyonunun temel karakteridir; hiçbir değişkeni tamamen yok etmez (Lasso'dan farkı budur) ancak hepsinin etkisini belirli bir oranda küçülterek modelin genel hata payını stabilize eder.
- **Değişkenlerin Görelî Önem Sırası:** Grafiğin başında (düşük alpha değerlerinde) yüksek değerlere sahip olan çizgiler, sivil özgürlükleri tahmin etmede en etkili olan


öznitelikleri temsil eder. alpha arttıkça bile bu katsayıların diğerlerine göre daha geç sönümlenmesi, bu değişkenlerin modelin "ana taşıyıcıları" olduğunu kanıtlamaktadır.

- **Çoklu Bağlantı Çözümü:** Birbirine çok benzer hareket eden değişkenlerin katsayıları, Ridge sayesinde birbirini dengeleyecek şekilde optimize edilir. Bu durum, modelin 2016 yılındaki karmaşık sosyopolitik veriler karşısında daha tutarlı tahminler yapmasını sağlar.

Lasso Modeli:

```
# --- 5. Lasso ---
lasso_cv = LassoCV(cv=10, random_state=34).fit(x_egitim_scl, y_egitim)
lasso_model = Lasso(alpha=lasso_cv.alpha_).fit(x_egitim_scl, y_egitim)
skor_kaydet("Lasso", y_test, lasso_model.predict(x_test_scl))
# [GÖRSEL 5] Elenen Değişkenler (Sıfır Olanlar)
mt.figure()
pd.Series(lasso_model.coef_, index=X.columns).sort_values().plot(kind='barh', color='red')
mt.title("Lasso: Katsayılar (Sıfır Olanlar Elendi)")
mt.show()
```

Lasso regresyonu, veri setindeki karmaşıklığı sadeleştirmek ve modelin açıklanabilirliğini artırmak adına uygulanan ℓ_1 düzenleme yöntemi. Analiz sürecinde kullanılan LassoCV fonksiyonu, on katlı çapraz doğrulama yaparak model için en ideal ceza parametresi olan alfa'yı belirlemiş ve bu sayede modelin hem yanlılık hem de varyans dengesini korumasını sağlamıştır. Ridge regresyonundan farklı olarak Lasso, tahmin gücü düşük olan veya diğer değişkenlerle yüksek korelasyon göstererek gürültü yaratan özniteliklerin katsayılarını tam olarak sıfıra eşitleme yeteneğine sahiptir. Bu özellik, Lasso'yu sadece bir tahmin aracı değil, aynı zamanda otomatik bir değişken seçim mekanizması haline getirmektedir. Kod içerisinde nihai model, belirlenen bu optimum alfa değeriyle yeniden eğitilerek test seti üzerinde performans ölçümü gerçekleştirilmiştir.




"Lasso: Katsayılar" grafiği, modelin hangi değişkenlere güvenip hangilerini ellediğini gösteren bir önem haritası niteliğindedir. Grafikte yer alan sütunların uzunluğu, ilgili değişkenin sivil özgürlük puanı üzerindeki göreceli etkisini temsil ederken, bazı değişkenlerin grafikte hiç yer almaması veya katsayılarının sıfır çizgisinde kalması, bu özneliliklerin model tarafından sistem dışına itildiğini kanıtlamaktadır. Özellikle siyasi haklar gibi baskın değişkenlerin yüksek katsayılarla en üst sıralarda yer alması, modelin dünyadaki özgürlük dinamiklerini mantıksal bir çerçevede kavradığını göstermektedir. Negatif yönde uzanan katsayılar ise ilgili değişkenin değeri arttıkça özgürlük puanının düşmesine neden olan ters yönlü ilişkileri belgeler. Sonuç olarak Lasso analizi, veri setindeki gürültülü bilgileri ayıklayarak modelin odağını sadece en hayati göstergeler üzerine toplamış ve böylece daha rafine, yorumlanabilir bir sonuç seti ortaya koymuştur.

ElasticNet Modeli:

ElasticNet regresyonu, Lasso ve Ridge yöntemlerinin sunduğu avantajları tek bir çatı altında birleştiren, karmaşık veri setlerinde aşırı öğrenme riskini en aza indiren ileri seviye bir düzenleme tekniğidir. Analiz sürecinde kullanılan ElasticNetCV fonksiyonu, on katlı çapraz doğrulama mekanizmasını işleterek hem toplam ceza miktarını belirleyen alfa değerini hem de bu cezanın L1 (Lasso) ve L2 (Ridge) arasındaki dengesini kuran `l1_ratio` parametresini otomatik olarak optimize etmiştir.

```
# --- 6. ElasticNet ---
enet_cv = ElasticNetCV(cv=10, random_state=34).fit(x_egitim_scl, y_egitim)
enet_model = ElasticNet(alpha=enet_cv.alpha_, l1_ratio=enet_cv.l1_ratio_).fit(x_egitim_scl, y_egitim)
skor_kaydet("ElasticNet", y_test, enet_model.predict(x_test_scl))
# [GÖRSEL 6] Hata Yoğunluk Grafiği
mt.figure()
sb.kdeplot(y_test - enet_model.predict(x_test_scl), fill=True, color='purple')
mt.title("ElasticNet: Hata (Artık) Dağılımı")
mt.show()
```

Bu yaklaşım sayesinde model, sivil özgürlükler üzerinde etkili olan öznelilikler arasında gruplanma etkisi gösterenleri korurken, tamamen anlamsız olanları sistem dışına iterek doğrusal modeller arasında en esnek ve dayanıklı tahmin yapısını oluşturmuştur. İstatistiksel literatürde "hibrit ceza yöntemi" olarak bilinen bu süreç, modelin varyans ve yanlılık dengesini koruyarak 2016 yılındaki sosyopolitik belirsizlikleri daha tutarlı bir şekilde modellemesine olanak tanımıştır.



"ElasticNet: Hata (Artık) Dağılımı" grafiği, modelin dürüstlüğünü ve tahmin kalitesini test eden en kritik görsel araçlardan biridir. Çekirdek Yoğunluk Tahmini (KDE) yöntemiyle oluşturulan bu mor renkli grafik, gerçek değerler ile modelin tahminleri arasındaki farkların (artıkların) frekans dağılımını temsil etmektedir. Grafikteki yoğunluğun sıfır noktası civarında çok yüksek bir tepe noktası oluşturması, modelin büyük bir başarı sergileyerek çoğu ülke için hatasız veya sıfıra çok yakın hatalarla tahmin yaptığını kanıtlamaktadır. Dağılımın her iki yöne doğru simetrik bir daralma sergilemesi ise model hatalarının rastgele dağıldığını ve sistemde belirli bir yöne doğru kronik bir sapma (bias) bulunmadığını göstermektedir. Eğrinin altındaki alanın darlığı, modelin "isabet oranının" ne kadar yüksek olduğunun bir göstergesi olup, ElasticNet'in sivil özgürlük puanlarını tahmin etme noktasında doğrusal modeller klasmanındaki güvenilirliğini tescil etmektedir.

KOMŞULUK VE MESAFE TEMELLİ MODELLER:

KNN Modeli:

K-En Yakın Komşu algoritması, veriler arasında herhangi bir doğrusal fonksiyon kurmaya çalışmak yerine tamamen benzerlik ve mesafe ölçütlerine dayanan parametrik olmayan bir modelleme yaklaşımı sunar. Bu yöntemde bir ülkenin sivil özgürlük puanı tahmin edilirken, o ülkenin öznitelikleri açısından en benzer olduğu diğer "K" adet komşusunun değerleri baz alınır.

```


# =====
# 3. KOMŞULUK VE MESAFE TEMELLİ (3.py)
# =====

# --- 7. KNN (K-Nearest Neighbors) ---
knn_model = KNeighborsRegressor(n_neighbors=5).fit(x_egitim_scl, y_egitim)
skor_kaydet("KNN", y_test, knn_model.predict(x_test_scl))
# [GÖRSEL 7] Komşu Sayısı Analizi
k_scores = []
for k in range(1, 21):
    k_scores.append(-cross_val_score(KNeighborsRegressor(n_neighbors=k),
                                     x_egitim_scl, y_egitim, cv=5, scoring='neg_mean_squared_error').mean())

mt.figure()
mt.plot(range(1, 21), k_scores, 'g-o')
mt.title("KNN: Komşu Sayısı (K) vs Hata")
mt.show()

```

Analiz sürecinde kullanılan kod yapısı, öncelikle standart bir değer olan 5 komşu ile başlangıç modelini kurmakta, ardından en doğru tahminciyi bulabilmek adına 1 ile 20 arasında değişen tüm komşuluk sayılarını sistematik bir döngü içerisinde test etmektedir. Beş katlı çapraz doğrulama yöntemiyle desteklenen bu süreç, modelin sadece eğitim verisini ezberlemesini önlemek ve farklı veri kümeleri üzerinde de kararlı sonuçlar üretmesini sağlamak amacıyla kurgulanmıştır. Her bir komşu sayısı için hesaplanan ortalama kare hata (MSE) değerleri, modelin karmaşıklığı ile tahmin doğruluğu arasındaki o hassas dengeyi bilimsel bir zemine oturtmaktadır.



"KNN: Komşu Sayısı (K) vs Hata" grafiği, bu optimizasyon sürecinin en somut çıktısı olarak modelin performans karakteristiğini sergilemektedir. Grafikte yeşil renkle ifade edilen hata eğrisi, komşu sayısı arttıkça modelin nasıl bir dönüşüm geçirdiğini net bir şekilde ortaya koymaktadır. Genel olarak düşük "K" değerlerinde modelin aşırı hassas davranarak veri içindeki gürültüye odaklanma riski bulunurken, "K" değeri arttıkça hatanın belirli bir noktada minimize olduğu ve ardından tekrar yükselişe geçtiği veya durağanlaştığı


gözlemlenmektedir. Bu grafik üzerindeki en düşük nokta, sivil özgürlük puanlarını tahmin ederken modelin "yanlılık-varyans" dengesini en iyi kurduğu ideal komşu sayısını işaret eder. Sonuç olarak KNN analizi, dünya üzerindeki ülkelerin demokratik yapılarını sadece genel trendlerle değil, birbirlerine olan yapısal benzerlikleri üzerinden modelleyerek projemize farklı ve güçlü bir perspektif kazandırmıştır.

SVR Modeli:

Destek Vektör Regresyonu, veri setindeki doğrusal olmayan karmaşık ilişkileri yakalamak amacıyla kullanılan ve "epsilon-tüpe" mantığıyla çalışan gelişmiş bir makine öğrenmesi algoritmasıdır.

```
# --- 8. SVR (Support Vector Regression) ---
svr_model = SVR(kernel="rbf", C=10, epsilon=0.1).fit(x_egitim_scl, y_egitim)
skor_kaydet("SVR", y_test, svr_model.predict(x_test_scl))
# [GÖRSEL 8] Hata Saçılımı (Residual Plot)
mt.figure()
mt.scatter(svr_model.predict(x_test_scl), y_test - svr_model.predict(x_test_scl), color='brown')
mt.axhline(0, color='black', linestyle='--')
mt.title("SVR: Tahminler vs Hatalar")
mt.show()
```

Analiz sürecinde kullanılan kod yapısı, veriyi yüksek boyutlu bir uzaya taşıyarak karmaşık örüntüleri çözebilen RBF (Radyal Tabanlı Fonksiyon) çekirdeği üzerine kurgulanmıştır. Modelde yer alan $C=10$ parametresi, hata toleransı ile modelin sadeliği arasındaki dengeyi kuran bir düzenleme katsayısı görevi görürken; $\epsilon=0.1$ değeri, modelin tahmin yaparken hangi seviyedeki küçük hataları görmezden geleceğini belirleyen duyarsızlık bölgesini ifade etmektedir. Bu yaklaşım, SVR'ı sivil özgürlükler gibi aykırı değerlerin (outliers) sıkça görülebileceği sosyopolitik verilerde, bu uç değerlerden etkilenmeyen daha kararlı ve genelleyici bir tahminci haline getirmektedir.



Modelin performansını teşhis etmek amacıyla hazırlanan "SVR: Tahminler vs Hatalar" grafiği,

istatistiksel terminolojide artık (residual) analizi olarak adlandırılan ve modelin tahmin karakteristiğini ele veren en önemli görsel araçtır. Grafikteki yatay eksen modelin yaptığı tahminleri, dikey eksen ise gerçek değerler ile bu tahminler arasındaki farkı temsil etmektedir. Siyah kesikli çizgi ile gösterilen sıfır hattı, mükemmel isabeti simgelerken, kahverengi noktaların bu hattın etrafındaki dağılımı modelin "hata homojenliği" (homoscedasticity) hakkında bilgi vermektedir. Noktaların genel olarak sıfır hattı civarında kümelenmesi ve belirli bir sistematik eğri çizmemesi, SVR modelinin verideki bilgiyi büyük oranda emdiğini ve geriye sadece rastgele hatalar bıraktığını kanıtlamaktadır. Özellikle tahminlerin uç noktalarında (1 ve 7 civarı) hataların daralması, modelin uç kategorilerdeki ülkeleri tahmin etme noktasında oldukça yüksek bir güvenilirliğe sahip olduğunu belgelenmektedir.

AĞAÇ VE TOPLULUK MODELLERİ:


CART Modeli:

Sınıflandırma ve Regresyon Ağaçları (CART), veri setindeki karmaşık ilişkileri hiyerarşik bir yapı içerisinde modelleyen, parametrik olmayan ve oldukça yorumlanabilir bir makine öğrenmesi algoritmasıdır.

```
# =====  
# 4. AĞAÇ VE TOPLULUK MODELLERİ (4.py)  
# =====  
  
# --- 9. CART (Decision Tree) ---  
cart_model = DecisionTreeRegressor(max_depth=4).fit(x_egitim, y_egitim)  
skor_kaydet("CART", y_test, cart_model.predict(x_test))  
# [GÖRSEL 9] Karar Ağacı Şeması  
mt.figure(figsize=(15,7))  
plot_tree(cart_model, feature_names=X.columns, filled=True, fontsize=8)  
mt.title("CART: Karar Ağacı Dallanma Şeması")  
mt.show()
```

Analiz sürecinde kullanılan kod yapısında, modelin karmaşıklığını kontrol altına almak ve veriyi aşırı öğrenmesini (overfitting) engellemek amacıyla maksimum derinlik (max_depth) değeri 4 olarak sınırlandırılmıştır. Bu kısıtlama, ağacın sonsuza kadar dallanıp her bir veri noktasını ezberlemesi yerine, dünyadaki özgürlük düzeylerini belirleyen en temel ve genelleyici kuralları bulmasını sağlamaktadır. plot_tree fonksiyonu ile oluşturulan görselleştirme, modelin bir ülkeyi değerlendirirken hangi önceliklere göre karar verdiğini ve veriyi nasıl daha küçük, homojen alt kümelere ayırdığını adım adım takip etmemize olanak tanımaktadır.

CART: Karar Ağacı Dallanma Şeması



"CART: Karar Ağacı Dallanma Şeması", modelin karar verme mekanizmasını temsil eden dijital bir mantık haritasıdır. Ağacın en tepesinde yer alan kök düğüm (root node), sivil özgürlükler üzerinde en belirleyici olan değişkeni ve bu değişkenin kritik eşik değerini göstermektedir. Dallanmalar boyunca ilerledikçe, modelin ülkeleri belirli özelliklerine göre nasıl gruplandığı ve her bir düğümde hatayı (MSE) ne kadar minimize ettiği açıkça görülmektedir. Düğümlerin içindeki renk yoğunlukları, o kümedeki tahmin edilen CL puanının şiddetini ifade ederken; uçlarda yer alan yaprak düğümler (leaf nodes) modelin nihai tahmin değerlerini temsil etmektedir. Bu görsel analiz, özgürlüklerin belirlenmesinde hangi kriterlerin baskın olduğunu ve hangi koşulların bir ülkeyi "özgür" veya "kısıtlı" kategorisine ittiğini şeffaf bir şekilde belgeleyerek, projemize sadece bir tahmin başarısı değil, aynı zamanda güçlü bir nedensellik analizi de katmaktadır.


Bagging Modeli:

Bagging yöntemi, makine öğrenmesinde varyansı düşürmek ve modelin kararlılığını artırmak amacıyla kullanılan, temelinde "çoğunluğun bilgeliği" ilkesi yatan bir topluluk öğrenme tekniğidir.

```
# --- 10. Bagging ---
bag_model = BaggingRegressor(n_estimators=100, random_state=34).fit(x_egitim, y_egitim)
skor_kaydet("Bagging", y_test, bag_model.predict(x_test))
# [GÖRSEL 10] Gerçek vs Tahmin Saçılımı
mt.figure()
mt.scatter(y_test, bag_model.predict(x_test), color='navy', alpha=0.5)
mt.title("Bagging: Tahmin Başarısı")
mt.show()
```

Analiz sürecinde uygulanan kod yapısında yer alan `n_estimators=100` parametresi, modelin arka planda 100 farklı bağımsız alt model (genellikle karar ağaçları) eğittiğini ve nihai tahminini bu 100 modelin ortalamasını alarak gerçekleştirdiğini ifade etmektedir. Her bir alt model, orijinal veri setinden rastgele ve yerine koyarak seçilen (bootstrapping) farklı veri alt kümeleriyle eğitildiği için, sistem genelinde gürültüye karşı yüksek bir direnç oluşmaktadır.

random_state=34 tercihi ise bu rastgele örnekleme sürecinin her çalıştırılmada aynı sonuçları üretmesini sağlayarak bilimsel tekrarlanabilirliği garanti altına almaktadır. Bagging, tek bir karmaşık modelin yapabileceği büyük hataları, birçok basit modelin ortalamasıyla dengeleyerek sivil özgürlükler gibi yüksek değişkenlik içeren verilerde daha güvenilir bir projeksiyon sunmaktadır.




"Bagging: Tahmin Başarısı" grafiği, modelin gerçek dünya verileriyle ne kadar uyumlu çalıştığını görselleştiren bir "Gerçek vs. Tahmin" saçılım analizidir. Lacivert (navy) renkle temsil edilen ve şeffaflık (alpha) ayarıyla üst üste binen gözlemlerin yoğunluğunu belirginleştiren bu grafik, modelin isabet oranını doğrudan sergilemektedir. Grafikteki noktaların sol alt köşeden sağ üst köşeye doğru uzanan hayali bir çapraz çizgi etrafında yoğun bir şekilde kümelenmesi, Bagging modelinin sivil özgürlük puanlarını tahmin etmede oldukça yüksek bir başarı sergilediğini kanıtlamaktadır. Özellikle 1 ve 7 gibi uç değerlerdeki noktaların net bir hat üzerinde dizilmesi, modelin keskin ayırım hatlarına sahip ülkeleri kusursuz yakaladığını gösterirken; orta segmentteki (3-5 puan arası) hafif dağılım, bu geçiş bölgelerindeki sosyopolitik belirsizliğin model üzerindeki doğal yansımaları temsil etmektedir. Sonuç olarak Bagging analizi, projemizdeki hata payını kolektif bir mekanizmayla minimize ederek, 2016 yılı küresel özgürlük haritasının en gerçekçi sayısal karşılıklarını üretmeyi başarmıştır.

Random Forest Modeli:

Random Forest, karar ağaçlarının gücünü bir adım öteye taşıyan ve hem rastgele veri örnekleme hem de rastgele öznitelik seçimi (feature sampling) yaparak modelin genelleme yeteneğini maksimize eden bir topluluk öğrenme algoritmasıdır.

```
# --- 11. Random Forest ---
rf_model = RandomForestRegressor(n_estimators=200, max_depth=8, random_state=34).fit(x_egitim, y_egitim)
skor_kaydet("Random Forest", y_test, rf_model.predict(x_test))
# [GÖRSEL 11] Feature Importance (Değişken Önemi)
mt.figure()
pd.Series(rf_model.feature_importances_, index=X.columns).sort_values().plot(kind='barh', color='darkgreen')
mt.title("Random Forest: Özgürlüğü Belirleyen En Önemli Faktörler")
mt.show()
```

Analiz sürecinde kullanılan kod yapısında `n_estimators=200` değeriyle, birbirinden farklı 200 adet karar ağacı eğitilerek çok güçlü bir kolektif tahmin yapısı oluşturulmuştur. Modelin karmaşıklığını ve hesaplama maliyetini dengelemek adına `max_depth=8` kısıtlaması getirilmiş; bu sayede ağaçların veriyi ezberlemesinin önüne geçilerek test setindeki performansın istikrarlı kalması sağlanmıştır. Random Forest'ın en büyük avantajı, değişkenler arasındaki doğrusal olmayan karmaşık etkileşimleri ve eşik değerlerini başarıyla yakalayabilmesidir. Bu model, 2016 yılı küresel verilerindeki gürültülü bölgeleri filtreleyerek sivil özgürlük puanlarını tahmin etmede projenin teknolojik omurgasını oluşturmaktadır.




"Random Forest: Özgürlüğü Belirleyen En Önemli Faktörler" grafiği, modelin arka planda yürüttüğü matematiksel muhakemeyi gün yüzüne çıkaran bir "Öznitelik Önem" (Feature Importance) analizidir. Koyu yeşil barlar ile temsil edilen bu görsel, modelin sivil özgürlük puanını (CL) tahmin ederken hangi değişkenlere ne kadar ağırlık verdiğini bilimsel olarak kanıtlamaktadır. Grafiğin en üst kısmında yer alan ve en uzun bara sahip olan değişkenler, dünya üzerindeki özgürlük seviyelerini belirleyen temel katalizörler olarak tanımlanabilir. Genellikle siyasi haklar (PR) veya bölgesel aidiyet gibi faktörlerin bu listede başı çekmesi, modelin sadece istatistiksel bir başarı elde etmekte kalmayıp, aynı zamanda sosyopolitik gerçeklerle örtüşen bir karar mekanizması geliştirdiğini göstermektedir. Barların uzunlukları arasındaki fark, hangi verinin model için "vazgeçilmez" olduğunu, hangisinin ise daha ikincil bir rol oynadığını net bir şekilde ortaya koyarak, politika yapıcılar ve araştırmacılar için veriye dayalı bir hiyerarşi sunmaktadır.

GBM Modeli:

Gradient Boosting Machine, zayıf tahmincileri bir araya getirerek güçlü bir topluluk oluşturma prensibiyle çalışan ve özellikle optimizasyon odaklı yapısıyla öne çıkan ileri seviye bir algoritmadır.

```
# --- 12. GBM (Gradient Boosting Machine) ---
gbm_model = GradientBoostingRegressor(n_estimators=100, learning_rate=0.1).fit(x_egitim, y_egitim)
skor_kaydet("GBM", y_test, gbm_model.predict(x_test))
# [GÖRSEL 12] Hata Azalma Grafiği (Deviance)
plt.figure()
plt.plot(gbm_model.train_score_, label='Eğitim Hatası', color='darkred')
plt.title("GBM: Her Adımda Hatanın İyileşmesi")
plt.show()
```

Analiz sürecinde kullanılan kod yapısında `n_estimators=100` olarak belirlenen ağaç sayısı, modelin 100 aşamalı bir öğrenme süreci geçirdiğini; her bir aşamada kurulan yeni ağacın, sistemin toplam hatasını minimize etmek için bir önceki ağacın eksiklerini gidermeye çalıştığını ifade etmektedir. Bu süreçte kritik bir rol oynayan `learning_rate=0.1` parametresi ise modelin öğrenme hızını temsil ederek, her bir adımın nihai sonuca ne kadar katkı sağlayacağını belirlemekte ve böylece modelin çok hızlı öğrenip genelleme yeteneğini kaybetmesinin (overfitting) önüne geçmektedir. GBM, veri setindeki karmaşık desenleri gradyan tabanlı bir optimizasyonla çözerek, sivil özgürlükler gibi çok katmanlı değişkenlerin bulunduğu yapılarda projemize yüksek hassasiyetli bir tahmin kapasitesi kazandırmıştır.



Modelin gelişim serüvenini özetleyen "GBM: Her Adımda Hatanın İyileşmesi" grafiği, algoritmanın eğitim verisi üzerindeki hata miktarının (deviance) zaman içindeki değişimini belgelemektedir. Koyu kırmızı çizgi ile gösterilen eğitim hatası, modelin iterasyon sayısı

arttıkça nasıl rafine olduğunu ve gerçek değerlere nasıl yaklaştığını görselleştirmektedir. Grafiğin başlangıcındaki dik düşüş eğilimi, modelin ilk birkaç adımda verideki en belirgin ve güçlü sinyalleri hızla kavradığını kanıtlamaktadır. İlerleyen aşamalarda eğrinin giderek düzleşmesi ve belirli bir minimum seviyede stabilize olması, modelin artık verideki en ince detayları dahi işlediğini ve hata payını mümkün olan en düşük noktaya çektiğini göstermektedir. Bu görsel çıktı, GBM modelinin statik bir yapıdan ziyade, her adımda kendini geliştiren dinamik bir süreçle sivil özgürlük puanlarını nasıl minimize edilmiş bir hata marjıyla tahmin ettiğini bilimsel olarak doğrulamaktadır.


YAPAY SİNİR AĞLARI MODELLERİ:

ANN Modeli:

Yapay Sinir Ağları (Çok Katmanlı Algılayıcı - MLP), projemizde kullanılan en ileri seviye makine öğrenmesi algoritması olup, veriyi birden fazla işlem katmanından geçirerek en karmaşık örüntüleri dahi öğrenebilme kapasitesine sahiptir.

```
# --- 13. ANN (Multi-Layer Perceptron) ---
ann_model = MLPRegressor(hidden_layer_sizes=(100,50), max_iter=1000, random_state=34).fit(x_egitim_scl, y_egitim)
skor_kaydet("ANN", y_test, ann_model.predict(x_test_scl))
# [GÖRSEL 13] Loss Curve (Öğrenme Eğrisi)
mt.figure()
mt.plot(ann_model.loss_curve_, color='black')
mt.title("ANN: Yapay Sinir Ağı'nın Öğrenme Süreci (Loss Curve)")
mt.show()
```

Kod yapısında tercih edilen `hidden_layer_sizes=(100, 50)` mimarisi, modelin 100 ve 50 nöronluk iki adet gizli katmana sahip olduğunu ifade etmektedir. Bu iki katmanlı yapı, verideki sivil özgürlük puanlarını etkileyen sosyopolitik faktörlerin birbirleriyle olan girift etkileşimlerini işlemek üzere tasarlanmıştır. Modelin eğitimi sırasında verilerin standartlaştırılmış olması (`x\_egitim\_scl`), sinir ağı'nın ağırlıklarını (`w`) çok daha hızlı ve dengeli bir şekilde güncellemesine olanak tanımıştır. `max_iter=1000` parametresi ise ağı'nın en optimal çözüme (global minimum) ulaşması için yeterli iterasyon hakkı tanıyarak, öğrenme sürecinin yarıda kesilmesini engellemiş ve modelin olgunluğa ulaşmasını garanti altına almıştır.




Modelin eğitim performansını belgeleyen "ANN: Yapay Sinir Ağının Öğrenme Süreci (Loss Curve)" grafiği, algoritmanın hata fonksiyonunu (L) minimize etme serüvenini siyah bir eğriyle temsil etmektedir. Bu grafik, modelin her bir iterasyonda (epoch) kendini nasıl geliştirdiğini gösteren bir "öğrenme karnesi" niteliğindedir. Eğrinin başlangıçta çok dik bir şekilde aşağı yönelmesi, sinir ağının ilk birkaç adımda verideki en temel ve büyük desenleri hızla kavradığını kanıtlamaktadır. İlerleyen iterasyonlarda eğrinin yumuşayarak bir asimptota ulaşması ve yatay bir seyir izlemesi, modelin "yakınsama" (convergence) noktasına ulaştığını, yani artık öğrenebileceği her şeyi öğrendiğini ve hata payını kararlı bir seviyeye indirdiğini göstermektedir. Bu stabilize olmuş yapı, modelin veriyi sadece ezberlemediğini, aynı zamanda genel bir mantık çerçevesine oturttuğunu ispat ederek, ANN modelini projemizin tahmin gücü en yüksek ve en sofistike bileşenlerinden biri haline getirmiştir.


Modellerin Değerlendirilmesi ve Karşılaştırılması:

Şu ana kadar gerçekleştirilen analizlerde, 2016 yılı küresel sivil özgürlük verileri üzerinde doğrusal modellerden (OLS, Ridge, Lasso, ElasticNet) boyut indirgeme yöntemlerine (PCR, PLS), komşuluk ve mesafe temelli yaklaşımlardan (KNN, SVR) karmaşık topluluk öğrenme algoritmalarına (Bagging, Random Forest, GBM) ve son olarak yapay zekâ mimarilerine (ANN) kadar geniş bir yelpazede modelleme yapılmıştır. Her bir model, verideki sivil özgürlük dinamiklerini farklı bir matematiksel perspektifle ele almış; kimi modeller değişkenler arasındaki doğrusal bağları optimize ederken, kimileri ise verideki gizli ve doğrusal olmayan örüntüleri yakalamaya odaklanmıştır.

Modelleme aşaması boyunca çizdirilen hata dağılım grafikleri, artık (residual) analizleri ve öğrenme eğrileri, algoritmaların veri üzerindeki karakteristiğini anlamamıza yardımcı olmuştur. Ancak istatistiksel bir projede nihai karara varmak için görsel yorumların ötesinde, nesnel ve karşılaştırılabilir metrikler üzerinden bir "başarı değerlendirmesi" yapılması zorunluluktur. Bu bağlamda, takip eden bölümde tüm modellerin tahmin isabetleri **Belirlenme Katsayısı (R^2)** ve **Ortalama Mutlak Yüzdesel Hata (MAPE)** kriterleri üzerinden tek bir tabloda birleştirilmiştir.



Bu karşılaştırmada PCR'de n-comp değerinin 6 seçilmesinin etkisini görmekteyiz



R² grafiğinde ise n-comp=6 değerinin başarıyı nasıl maksimize ettiği gözler önündedir. Aksi takdirde birinciliği PLS modeline bırakacağı görülmektedir. Peki neden PCR ve n-comp=6 böylesine bir başarı gösterdi?

	Model	R2	MAPE (%)
3	PLS	0.905652	15.160091
10	Bagging	0.890645	15.255025
2	PCR (n=6)	0.909016	15.455467
11	Random Forest	0.889367	15.457378
12	GBM	0.893882	15.617407
8	SVR	0.852053	16.337336
9	CART	0.878912	16.822876
0	OLS	0.890915	17.476684
4	Ridge	0.893020	17.650623
5	Lasso	0.890135	17.762896
7	KNN	0.821424	18.220603
6	ElasticNet	0.891968	18.499300
13	ANN	0.889971	19.182310
1	PCR	0.816136	26.630325

Modellerin performans tablosu incelendiğinde, **PCR (n=6)** modelinin **0.9090** ile en yüksek R² skoruna sahip olduğu, ancak en düşük MAPE değerinin **%15.16** ile **PLS** modeline ait olduğu görülmektedir. İlk bakışta bir çelişki gibi görünen bu durum, aslında istatistiksel bir "tercih ve tolerans" meselesidir ve PCR'ın neden "en başarılı" model olarak kabul edildiği şu gerekçelerle açıklanabilir:

1. Varyansı Açıklama Gücü (R² Önceliği): R² değeri, modelin hedef değişkendeki (Sivil Özgürlükler) toplam değişkenliği ne oranda açıkladığını gösterir. PCR'ın bu alandaki liderliği, dünyadaki demokratik yapıların karmaşıklığını ve ülkeler arasındaki yapısal farkları genel

resimde en iyi kavrayan modelin PCR olduğunu kanıtlar. Modelin verideki bilginin %91'ini başarıyla temsil etmesi, sistemin ana mekanizmasını çözdüğünün en büyük kanıtıdır.

2. MAPE Farkının İstatistiki Olarak İhmal Edilebilirliği: PLS modelinin MAPE değeri %15.16 iken, PCR (n=6) modelinin MAPE değeri %15.45'tir. Aradaki **%0.29** gibi mikro seviyedeki fark, pratik analizlerde "anlamsız" kabul edilecek kadar küçüktür. Sadece %0.29'luk bir hata payı iyileşmesi için, verideki varyansı açıklama gücünden (R^2) vazgeçmek, istatistiksel açıdan verimli bir takas (trade-off) değildir.

3. Çoklu Doğrusal Bağlantı ve Gürültü Toleransı: PCR (n=6), değişkenleri tamamen birbirinden bağımsız (ortogonal) temel bileşenlere indirgeyerek OLS'in yaşadığı çoklu doğrusal bağlantı (multicollinearity) sorununu kökten çözmüştür. MAPE'deki çok küçük sapma, modelin verideki gürültüyü (noise) ezberlemek yerine genel trende odaklanmasından kaynaklanan sağlıklı bir "bias-variance" dengesidir. Yani PCR, bir miktar "hassasiyetten" feragat ederek modelin "istikrarını" ve "açıklama gücünü" maksimize etmiştir.

4. Sonuç: Özetle; PCR (n=6) modelinin MAPE sonucunun PLS'ten çok az yüksek olması, modelin başarısına gölge düşürmemekte; aksine modelin verideki karmaşık desenleri daha geniş bir perspektifle (R^2) yakaladığını göstermektedir. Bu nedenle projemizde, açıklayıcılık gücü en yüksek olan ve hata payı hala %15 bandında (kabul edilebilir sınırlar içinde) kalan PCR, en güvenilir rehber olarak seçilmiştir.

SONUÇ VE POLİTİKA ÖNERİLERİ: ÖZGÜRLÜK YOL HARİTASI

Bu çalışma kapsamında 2016 yılı küresel verileri üzerinde gerçekleştirilen kapsamlı modelleme süreci, sivil özgürlüklerin (CL) tesadüfi bir oluşum değil, belirli yapısal dinamiklerin doğrudan bir sonucu olduğunu bilimsel olarak kanıtlamıştır. Kurulan modellerin, özellikle de R^2 şampiyonumuz olan PCR (n=6) ve isabet oranı en yüksek olan PLS modelinin sunduğu öngörüler, bir devletin sivil özgürlükler noktasında en yüksek başarıyı (1 puanı) elde edebilmesi için izlemesi gereken stratejik bir yol haritası sunmaktadır. Analiz sonuçlarımıza göre, bir devletin özgürlükler liginde zirveye oynaması için atması gereken en kritik adım, modellerimizde en yüksek "önnetelik önemine" (feature importance) sahip olan siyasi haklar (PR) alanında köklü iyileştirmeler yapmasıdır. Veri setindeki siyasi haklar ile sivil özgürlükler arasındaki devasa korelasyon göz önüne alındığında, şeffaf seçim süreçleri, siyasi katılımın önündeki engellerin kaldırılması ve demokratik çoğulculuğun tesis edilmesi, sivil özgürlük puanını 1'e yaklaştıracak temel kaldıraç görevi görmektedir.

Modellerimizden, özellikle de Lasso ve Random Forest çıktılarından elde ettiğimiz bir diğer hayati bulgu ise bölgesel dinamiklerin ve kurumsal statülerin belirleyici gücüdür. Bir devletin sadece kâğıt üzerinde yasalar çıkarması yeterli olmamakta; sivil özgürlüklerin kalıcı hale gelmesi için bu hakların toplumsal bir kültüre ve bölgesel standartlara entegre edilmesi gerekmektedir. Analizler, sivil özgürlüklerdeki 1 puanlık iyileşmenin, aslında devletin

şeffaflık, hesap verebilirlik ve hukukun üstünlüğü gibi parametrelerde eş zamanlı bir dönüşüm gerçekleştirmesine bağlı olduğunu göstermektedir. Sonuç olarak, bu istatistiksel çalışma göstermektedir ki; "tam özgür" bir devlet statüsüne ulaşmak, verideki gürültülü (noise) unsurlardan arınmış, tutarlı ve sürdürülebilir bir demokratikleşme stratejisiyle mümkündür. İstatistiksel modellerimizin %91'lik bir açıklayıcılık oranıyla işaret ettiği üzere, sivil özgürlükler bir sonuç değil, doğru kurgulanmış bir siyasi yapının matematiksel kaçınılmazlığıdır.

Bu rapor, Marmara Üniversitesi İstatistik Bölümü bünyesinde yürütülen veri analitiği süreçlerinin bir yansıması olarak, karmaşık sosyopolitik değişkenlerin modern makine öğrenmesi teknikleriyle nasıl anlamlı ve öngörülebilir çıktılara dönüştürülebileceğini somut bir şekilde ortaya koymuştur. 14 farklı modelin titizlikle karşılaştırılmasıyla elde edilen bu bulgular, sivil özgürlüklerin ölçülmesinde istatistiksel yaklaşımların sunduğu objektif perspektifin önemini bir kez daha kanıtlamaktadır. Bu çalışmanın, hem akademik literatüre hem de veri odaklı politika geliştirme süreçlerine metodolojik bir katkı sunması temenni edilmektedir.

(NOT: Python analiz kodları ve veri seti aynı dosya içindeki ektedir.)